

Fórmula 1

Bases de datos



Integrantes:

Edwin Leal Guadalajara

María Fernanda Sánchez Rentería

Fernanda Zambrano Gudiño

Kevin Javier Pérez Meza

Introducción

Este proyecto será realizado con base en datos de la Fórmula 1, la información se obtuvo a través de Kaggle, la cual se subió a Github para obtener el url de los datos en crudo. La base de datos cuenta con varias carpetas, por conveniencia se seleccionaron 3 datasets para facilitar la codificación y trabajar con este nuevo data frame en conjunto con otras materias.

- **Pit Stops.csv** contiene información detallada sobre las paradas en boxes (pit stops) de los pilotos durante las carreras. Incluye race Id, driverId, número de parada (stop), tiempo y duración de la parada.
- **Drivers.csv** nos proporciona información sobre los pilotos de Fórmula 1, como driverId, drive Ref, forename (nombre) y la nacionalidad.
- **Drivers standings.csv** registra la posición y puntos de los pilotos en el campeonato después de cada carrera, incluyendo race Id, driverId y la posición.

Justificación

El dataset, en contexto a bases de datos, será sometido a un análisis para hacer un modelo relacional con las tres bases de datos, esto permitirá obtener

- Enriquecer los datos de pit stops: Al fusionar pit stops.csv con drivers.csv, se asocian los tiempos de paradas en boxes, el identificador de pilotos y nacionalidad de los pilotos.
- Relacionar pit stops con el rendimiento: La fusión con drivers standings.csv permite vincular las paradas con la posición final de los pilotos en la carrera, lo cual es esencial para determinar si una parada en box rápida o lenta influye en el resultado.
- Análisis de clasificación: Se crea una variable clase a partir de la posición (posición) del piloto, categorizando si el piloto terminó en el podio (Top 3) o dentro de los puntos (Top 10), lo que facilita el análisis de clasificación y la construcción de modelos predictivos.

Fuente de Datos

La información para este proyecto se obtuvo directamente de un archivo CSV disponible en un repositorio de GitHub — utilizando su versión *raw*. Para su integración, los datos se cargaron en Google Colab utilizando la librería pandas a través de la función `pd.read_csv()`. Esta metodología asegura la transparencia y la trazabilidad de los datos, ya que la fuente es pública y permite la verificación directa del contenido original.

Tipo de datos:

Categoría (columna)	Tipo de dato	Descripción
raceId	Entero (int64)	Identificador único de la carrera en la que participa el piloto.
driverId	Entero (int64)	Identificador único del piloto dentro del sistema.
stop	Entero (int64)	Número de paradas en pits realizadas por el piloto en la carrera.
seconds	Decimal (float64)	Tiempo total acumulado en pits, expresado en segundos.
driverRef	Texto (object)	Referencia corta o código del piloto (ej. <i>raikkonen</i> , <i>stroll</i>).
forename	Texto (object)	Nombre del piloto.
nationality	Texto (object)	Nacionalidad del piloto.
position	Decimal (float64)	Posición final del piloto en la carrera (ej. 1 = primero, 10 = décimo).
clase	Tupla (0, 1)	Clasificación derivada: 1 = podio (top 3), 0 = puntos (posiciones 4–10).

Diagrama de flujo





Diagrama de entidad de relación



Descripción del modelo relacional

drivers (1) → pit_stops (N): Cada piloto puede tener múltiples registros de paradas en pits, pero cada parada pertenece a un solo piloto.

drivers (1) → standings (N): Un piloto puede aparecer en varias posiciones finales (una por carrera), pero cada posición corresponde a un único piloto.

races (1) → pit_stops (N): Una carrera puede tener muchas paradas en pits, pero cada parada pertenece a una sola carrera.

races (1) → standings (N): Una carrera puede tener múltiples resultados (uno por piloto), pero cada resultado pertenece a una sola carrera.

El modelo relacional de este proyecto se compone de cuatro entidades principales: *drivers*, *races*, *pit_stops* y *standings*. Las relaciones entre ellas son de tipo **uno a muchos (1:N)**, reflejando la naturaleza jerárquica de los datos deportivos: un piloto y una carrera pueden generar múltiples registros asociados en las tablas de paradas y resultados. Este diseño facilita la integridad referencial y el análisis cruzado de desempeño por carrera y piloto.

a línea, plano o hiperplano de mayor dimensión) que separe de manera óptima dos o más clases de datos.

Aplicación de un modelo de Machine Learning: Regresión logística

Logistic Regression (LR)

A diferencia de la regresión lineal (que predice números continuos), la regresión logística predice la probabilidad de que una entrada pertenezca a una categoría específica.

Se utiliza comúnmente para resultados con dos categorías posibles, por ejemplo: Sí/No, Verdadero/Falso o 0/1; utiliza esta función matemática para convertir cualquier valor de entrada en un valor de probabilidad entre 0 y 1.

El resultado no es una clasificación directa, sino la probabilidad (p) de que un evento ocurra, además los coeficientes del modelo se ajustan buscando maximizar la probabilidad de observar los datos reales (Maximum Likelihood Estimation - MLE)

Aplicación en Google Colab:

evaluando el modelo LR

accuracy(train): 0.7658491439148543

accuracy(test): 0.7855822550831792

recall(train): 0.7658491439148543

recall(test): 0.7855822550831792

precision(train): 0.7600327335036162

precision(test): 0.7778920357032411

f1(train): 0.7620694471181098

f1(test): 0.7793378265099784

Conclusión

Como se ha demostrado en este análisis, desde la recopilación inicial de los datos hasta su preprocesamiento y la aplicación de modelos de Machine Learning, cada etapa depende críticamente de una gestión de datos robusta. La capacidad de almacenar grandes volúmenes de información, asegurar su calidad y accesibilidad, y organizarla de manera que facilite la extracción de sus

perspectivas características es lo que nos permite que los algoritmos de machine learning aprendan de forma efectiva y generen resultados útiles.

En el ámbito enfocado a ciencias de datos e inteligencia artificial nos permite garantizar que los datos sean confiables y estén siempre accesibles para su uso en modelos predictivos y analíticos, además de que la calidad y la estructuración de nuestros datos impactan directamente en la precisión y eficiencia de los modelos de Machine Learning.

Uso de inteligencia artificial

En la sección de visualización del gráfico del diagrama de entidad de relación se utilizó inteligencia artificial como apoyo en esa área del reporte.

Referencias

https://github.com/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/tree/main

https://raw.githubusercontent.com/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/refs/heads/main/data/formula1/pit_stops.csv

https://raw.githubusercontent.com/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/refs/heads/main/data/formula1/drivers.csv

https://raw.githubusercontent.com/IvTole/MachineLearning_InferenciaBayesiana_CUGDL/refs/heads/main/data/formula1/driver_standings.csv