

Fórmula 1

Fernanda Zambrano, María Fernanda Sánchez, Edwin Leal, Kevin Pérez
UDG

18 de mayo de 2026

Resumen

Se analiza la relación entre el número de pit stops y la posición final de los pilotos en carreras de Fórmula 1. Para ello se realizó un proceso de limpieza e integración de datos de la F1 provenientes de Kaggle, generando un conjunto de datos estructurados. Se hicieron uso de distintas pruebas estadísticas: prueba de ANOVA de un factor, observaciones pareadas y de una prueba de independencia χ^2 para así determinar la eficiencia y el rendimiento de ciertos pilotos seleccionados.

1. Introducción

En competiciones deportivas como lo es la Fórmula 1 influyen varios factores que llegan a repercutir significativamente en el resultado final de una carrera, estos eventos requieren ser evaluados mediante pruebas estadísticas. Desde el enfoque de probabilidad y estadística, es posible ver la variabilidad de nuestros datos y analizar si las diferencias observadas entre distintos grupos son casualidades o es un efecto real. En este proyecto se analiza la relación entre el número de pit stops y la posición final de los pilotos buscando si el número de paradas en pits tiene impacto estadísticamente en el desempeño de los pilotos usando pruebas de observaciones pareadas, ANOVA, y prueba de independencia χ^2 las cuales permitirán evaluar y establecer conclusiones sobre el desempeño de los conductores en ciertos escenarios.

2. Planteamiento del problema

En el contexto de la Fórmula 1, la estrategia de carrera juega un papel fundamental en el resultado final de los pilotos. Uno de los elementos más relevantes dentro es el número de pit stops realizados durante una carrera, ya que estos influyen tanto en el tiempo total como en el desempeño del vehículo en pista. Sin embargo, no es evidente si existe una relación directa y significativa entre la cantidad de paradas en pits y la posición final obtenida por los pilotos.

Desde el enfoque de la estadística, surge la necesidad de analizar si las diferencias observadas en las posiciones finales, al agrupar a los pilotos según su número de pit stops, son producto del azar o si reflejan un efecto real. En este sentido, se plantea evaluar si el número de paradas en pits tiene un impacto significativo en el desempeño de los pilotos.

Por lo tanto, el problema central de este estudio consiste en determinar si existen diferencias estadísticamente significativas en la posición final de los pilotos en función del número de pit stops realizados durante una carrera.

3. Observaciones pareadas

Una prueba de muestras pareadas es un método estadístico de estimación de la diferencia de dos medias cuando las muestras no son independientes. Esta prueba necesita de medir al sujeto u objeto dos veces para determinar si sus medias son distintas de cero.

Se debe asumir que:

- Las poblaciones se comportan aproximadamente normal.

- Los datos no son variables independientes.

- Los datos no pueden ser variables aleatorias.

Se establece un intervalo de confianza del $100(1 - \alpha)\%$ para $\mu_1 - \mu_2 = \mu_D$

$$\bar{d} - t_{\alpha/2}(n-1) \frac{S_d}{\sqrt{n}} < \mu_D < \bar{d} + t_{\alpha/2}(n-1) \frac{S_d}{\sqrt{n}} \quad (1)$$

donde $t_{\alpha/2}$ es el valor de t con $\nu = n - 1$ grados de libertad

3.1. Shapiro-Wilk

Uno de los supuestos, como ya se había mencionado, es que los datos deben distribuirse aproximadamente normal. Es por esto que primero es necesario determinar que los datos a utilizar cumplan con esa suposición, para esto se realizará una prueba de Shapiro-Wilk.

Esta prueba establece dos hipótesis:

H_0 : Los datos siguen una distribución normal.

H_1 : Los datos no siguen una distribución normal.

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{B^2}{S^2} \quad (2)$$

$x_{(i)}$ representa el número que toma la milésima posición en la muestra — los datos deben estar ordenados de mayor a menor.

Los coeficientes utilizados para la prueba de Shapiro-Wilk se obtienen a partir de: $a_i = \frac{m^T V^{-1}}{(m^T V^{-1} V^{-1} m)^{1/2}}$ Donde V es la matriz de covarianza de los estadísticos de orden (es decir, que los valores de la muestra n están ordenados de mayor a menor.

El valor de W oscila entre 1 y 0, cuando el valor de W es pequeño significa que se rechaza la hipótesis nula, es decir que los datos no se comportan de manera normal. En caso contrario si W es grande se concluye que no se puede rechazar la hipótesis nula.

Computar los coeficientes de esta prueba demanda de un gran almacenamiento, por lo que se hará uso de tablas de coeficientes.

En primera instancia se define el problema a tratar: se tienen las posiciones de las primeras 10 carreras registradas y las últimas 10 carreras registradas del piloto Raikkonen. La prueba pareada determinará si el conductor ha mejorado o empeorado el rendimiento de posiciones a comparación de sus primeras y últimas carreras.

Raikkonen		
First races	Last races	Difference
7	7	0
7	8	1
8	9	1
7	10	3
4	8	4
6	9	3
6	8	2
6	9	3
5	8	3
4	9	5

Se realiza la prueba de Shapiro-Wilk manual de la siguiente forma:

y_i	y_i^2	a_i	$y_{n-i+1} - y_i$	$a_i(y_{n-i+1} - y_i)$
0	0	0.5739	5-0 = 5	0.5739(5) = 2.8695
1	1	0.3291	4-1 = 3	0.3291(3) = 0.9873
1	1	0.2141	3-1 = 2	0.2141(2) = 0.4282
2	4	0.1224	3-2 = 1	0.1224(1) = 0.1224
3	9	0.0039	3-3 = 0	0.0039(0) = 0
3	9	-	-	-
3	9	-	-	-
3	9	-	-	-
4	16	-	-	-
5	25	-	-	-

$$\sum_{i=1}^n y_i = 25$$

$$\sum_{i=1}^n y_i^2 = 83$$

$$\sum_{i=1}^n a_i(y_{n-i+1} - y_i) = 4,4074$$

$$B = 4,4074$$

Se saca la media y varianza del conjunto y_i :

$$\bar{y} = \frac{25}{10} = 2,5$$

$$S^2 = 83 - 10(2,5)^2 = 20,5$$

El valor de W el cual es el estadístico que determinará si el conjunto se comporta de manera normal, se obtiene de la siguiente manera: $W = \frac{B^2}{S^2} = \frac{(4,4074)^2}{20,5} = 0,9475$ lo que aprueba la hipótesis nula: los datos se distribuyen aproximadamente normal.




Figura 1: Q-Q plot Raikkonen

3.2. Intervalo de confianza

Teniendo estos valores se comienzan a obtener las partes necesarias para crear el intervalo de confianza:

$$\bar{d} = 2,5$$

$$S_d = 1,509$$

$$t_{\alpha/2} = \pm 2,25$$

El valor t se obtiene a partir de la siguiente aproximación implementada con Python:

```
n = len(dif)
nu = n - 1
z_arr = np.linspace(-10, 10, 1000)
ss = 0
for zval in z_arr:
    prob = integrate.quad(tdist, -np.inf,
                          zval, args=(nu))
    if prob[0] >= 0.975:
        pto_crit = z_arr[ss-1]
        print(f'Pto. critico: {pto_crit}')
        break
    ss += 1
```

El intervalo de confianza quedaría de la siguiente manera:

$$1,42 < \mu_d < 3,57 \quad (3)$$

Esto indica que con un alpha o nivel de significancia de 0.05, se dice que se tiene un 95 % de confianza de que Raikkonen terminó en promedio de 1.42 a 3.57 posiciones atrás en sus últimas carreras registradas a comparación de sus primeras carreras registradas.

Se utilizó la prueba de Shapiro-Wilk debido al tamaño reducido de la muestra. Aunque esta prueba es adecuada para muestras pequeñas, existe la posibilidad de no detectar ciertas desviaciones de normalidad (error tipo II), lo que podría influir en la validez de la prueba t.

4. Prueba de independencia χ^2

Esta prueba confirma si es plausible que dos variables (en este caso, variables categóricas) están o no relacionadas.

Cuenta con las hipótesis:

H_0 : La variable 1 y la variable 2 no están relacionadas.

H_1 : La variable 1 y la variable 2 están relacionadas.

Para este problema se plantea la siguiente pregunta: ¿hacer más paradas en boxes se asocia con un peor resultado en la posición? Con el propósito de responder la pregunta, se inicializa creando una tabla de contingencia:

clase stops	1	0	-
clase podio	-	-	Total
1	764	68	832
0	1744	125	1870
Total	2508	194	2702

Notamos entonces que se tiene una tabla con dos filas y dos columna (2x2) es por ello que se utiliza la corrección de Yates:

$$\sum_i \frac{(|o_i - e_i| - 0,5)^2}{e_i} = 1,5706 \quad (4)$$

Los grados de libertad se obtienen a partir de la siguiente fórmula: $(r-1)(c-1)$ que en este caso sería: $(2-1)(2-1) = (1)(1) = 1$

Tenemos un nivel de significancia de: $\alpha = 0,05$ lo cual deja la integral:

$$\int_{\chi^2_{0,05,\nu=1}}^{\infty} f(x) dx = 0,05 \quad (5)$$

El valor aproximado de χ^2 se obtiene con las siguientes líneas de código implementadas en Python:

```
def chi2(x, nu):
    num = (x**(nu*0.5-1))*np.exp(-x*0.5)
    den = 2.0**(nu*0.5)*gamma(nu*0.5)
    return num/den

z_arr=np.linspace(0.001, 10, 1000)
nu= 1 #(r-1)(c-1) = (2-1)(2-1) = 1

ss =0
for zval in z_arr:
    prob = integrate.quad(chi2, 0.001, zval,
                           args=(nu))

    right_tail=1-prob[0]
    if right_tail<= 0.05:
        print(z_arr[ss-1])
        break
    ss += 1
```

Lo cual da como resultado $\approx 3,924$, comparando χ^2 con el valor de $\chi^2_{critico}$ se obtiene que: $\chi^2 < \chi^2_{critico}$.




Figura 2: Chi-cuadrada con 1 grado de libertad

La corrección de Yates reduce la probabilidad de cometer un error tipo I, ya que hace más conserva-

dora la decisión de rechazar la hipótesis nula. Al interpretar el resultado se obtiene que las paradas en boxes y estar en el podio son independientes.

5. ANOVA

El análisis de varianza (ANOVA) permite comparar múltiples grupos para determinar si existen diferencias significativas entre sus medias. En este proyecto los grupos fueron definidos según el número de pit stops realizado por los pilotos.

Fórmulas: Suma de cuadrados entre grupos:

$$SSA = n \sum_{i=1}^k (\bar{y}_i - \bar{y})^2$$

Suma de cuadrados del error:

$$SSE = \sum (x_{ij} - \bar{x}_i)^2$$

Suma de cuadrados totales

$$SST = SSA + SSE$$

Prueba F

$$F = \frac{S1}{S2}$$

Lógica matemática en el código

```
def SSA(n, k, yi_mean, y_mean):
```

```
    summ = 0.0

    for i in range(k):

        summ += (yi_mean[i] - y_mean)**2

    return n * summ
```

Creación de grupos

```
yij1 = np.array([2, 3, 4, 5])
yij2 = np.array([5, 6, 7, 8])
yij3 = np.array([8, 9, 7, 10])
```

Resultados

$SSA = 50,67$ $S1 = 25,33$ $SSE = 15,00$ $S2 = 1,67$
 $F = 15,2$

El análisis ANOVA permitió comparar las posiciones finales de los pilotos agrupados según el número de pit stops realizados durante las carreras. Los resultados obtenidos mostraron que la variabilidad entre grupos fue considerablemente mayor que la variabilidad dentro de los grupos, reflejándose en un valor elevado del estadístico F. Esto indica que existen diferencias significativas entre los grupos analizados, es decir que las medias de cada grupo son distintas.

Debido al tamaño de muestra y la variabilidad presente dentro de los grupos, existe la posibilidad de cometer un error tipo II, es decir, no detectar diferencias reales entre las medias.

6. Conclusiones

A partir de las distintas pruebas estadísticas se obtienen conclusiones para cada planteamiento. En el caso de observaciones pareadas del dataset se tomaron las primeras 10 y las últimas 10 carreras de cierto piloto — en este caso se tomó el ejemplo de Raikkonen quien fue uno de los pilotos que contaba con una distribución aproximadamente normal de la diferencia de sus carreras, una vez confirmado que siguen una campana de Gauss se hace el intervalo de confianza de $t_{\alpha/2}$ con un $\alpha = 0,05$ y $\nu = 9$ se obtiene que en promedio Raikkonen se ha posicionado entre 1.42 a 3.57 posiciones atrás en sus últimas carreras

Se realizó una prueba de independencia χ^2 con el objetivo de determinar si la cantidad de paradas en boxes se relaciona con quedar en una posición final peor. A través de la tabla de contingencia se obtiene que estas dos variables son independientes ya que $\chi^2 < \chi^2_{crit}$ o $1,5706 < 3,924$ lo cual acepta la hipótesis nula.

La prueba de ANOVA determina si las medias de tres o más grupos son iguales, para este caso se tomaron datos de los pilotos agrupados según su posición y paradas en boxes. Al obtener un valor F grande obtenemos que la hipótesis nula se rechaza — al menos una media no es igual.

A partir de este análisis estadístico, se puede inferir que las estrategias de pits representan un factor

importante dentro del desempeño competitivo de los pilotos durante las carreras.

7. Referencias

- JMP. (s. f.). *ANOVA de un factor*. <https://www.jmp.com/es/statistics-knowledge-portal/one-way-anova>
- Malato, G. (2025, 1 agosto). *An Introduction to the Shapiro-Wilk Test for Normality. Built In* <https://builtin.com/data-science/shapiro-wilk-test>
- Walpole, R., Myers, R., Myers, S., & Keying, Y. (2012). *Probabilidad y estadística para ingeniería y ciencias* (9.a ed.) [Pearson Educación de México, S.A. de C.V.]. Mario Contreras. <https://acortar.link/esKPWH>
- IvTole. (s. f.). *03_distribuciones_probabilidad_comunes.ipynb* [Notebook de Jupyter]. GitHub repository.
- Statistics Solutions. (2026, 16 abril). *Paired Sample T-Test - Statistics solutions*. <https://www.statisticssolutions.com/free-resources/directory-of-statistical-analyses/paired-sample-t-test/>